# 带噪二维数据的线性拟合与可复现性验证

匿名

**摘要**

本文针对一组固定保存的带噪二维合成数据，建立带截距的一元线性最小二乘模型，通过独立子进程执行求解代码，并以结构化结果驱动图、表与本文生成。样本数为 36，拟合得到斜率 2.557205、截距 3.133504，均方根误差为 0.819939，决定系数为 0.988464。该示例只验证工程闭环，不代表真实竞赛数据或现实规律。

## 1 问题说明

给定文件 `data.csv` 中的观测对 $(x_i, y_i)$，要求估计线性关系，计算误差指标，分析残差，并生成可追溯的中文报告。输入是固定保存并进行哈希跟踪的 synthetic fixture；正式运行只读取该文件，不依赖重新生成观测。

## 2 模型假设

1. 在给定区间内，响应变量的条件均值可由线性函数近似；
2. 观测误差均值为零，且本示例不据此主张样本外泛化；
3. 所有观测在拟合中权重相同，输入文件无缺失值。

## 3 符号说明

| 符号 | 含义 |
|---|---|
| $x_i$ | 第 $i$ 个自变量观测 |
| $y_i$ | 第 $i$ 个响应变量观测 |
| $\hat{y}_i$ | 模型预测值 |
| $e_i = y_i - \hat{y}_i$ | 残差 |
| $a, b$ | 斜率和截距 |

## 4 模型建立

采用模型

$$\hat{y}_i = a x_i + b, \tag{1}$$

并最小化残差平方和 $\sum_i (y_i - a x_i - b)^2$。误差指标定义为

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_i e_i^2}, \qquad \mathrm{MAE} = \frac{1}{n}\sum_i |e_i|, \tag{2}$$

$$R^2 = 1 - \frac{\sum_i e_i^2}{\sum_i (y_i - \bar{y})^2}. \tag{3}$$

## 5 求解方法

求解程序使用 SciPy 的非线性最小二乘接口估计 $a, b$，但模型本身为线性函数。Python `random` 和 NumPy 随机种子均固定为 20260710；求解阶段不重新生成数据。实际源码、命令、输入哈希、环境摘要、stdout 与 stderr 均保存在当前 run 目录。

## 6 结果

参数估计见表 1，误差指标见表 2。

表 1: 线性模型参数估计

| 参数 | 符号 | 原始数值 | 展示数值 |
|---|---|---|---|
| 斜率 | a | 2.5572047133 | 2.557205 |
| 截距 | b | 3.1335039092 | 3.133504 |

表 2: 拟合误差指标

| 指标 | 原始数值 | 展示数值 |
|---|---|---|
| RMSE | 0.8199391781 | 0.819939 |
| MAE | 0.6476007559 | 0.647601 |
| $R^2$ | 0.9884643818 | 0.988464 |
| 最大绝对误差 | 1.8165114730 | 1.816511 |

原始观测与拟合曲线见图 1。该图直接读取实际预测结果生成。

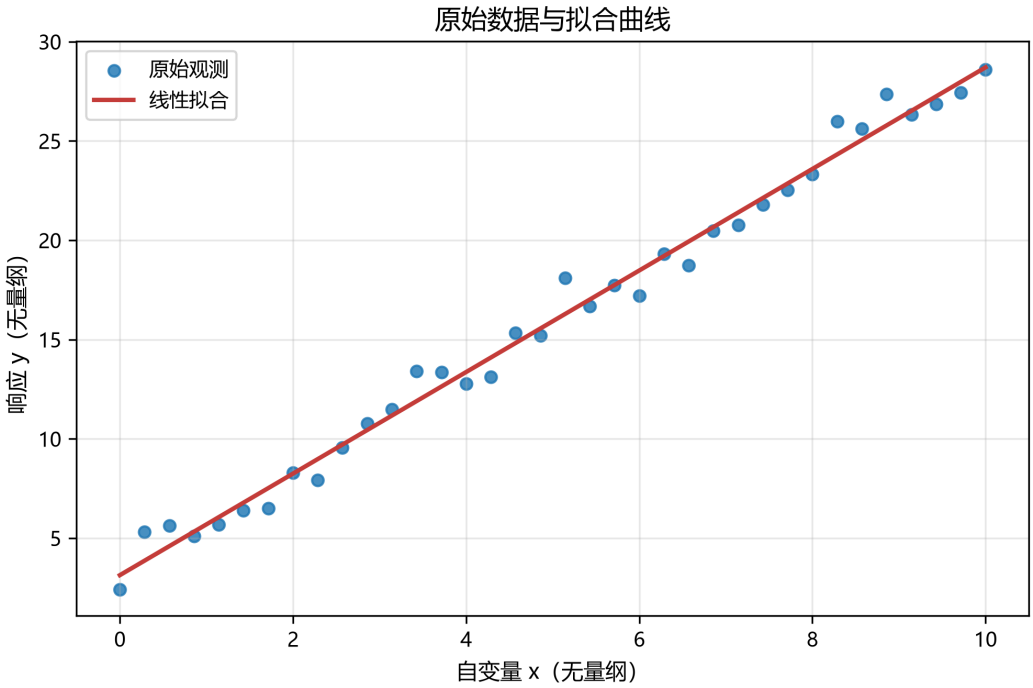



图 1: 原始数据与实际拟合曲线

## 7 误差分析

本次运行的 MAE 为 0.647601，最大绝对误差为 1.816511。独立验证器计算的残差均值为 -2.060e-15，在容差范围内接近零。图 2 给出残差随 $x$ 的变化；图中未见需要在本工程 fixture 中进一步建模的明显单调趋势，但该视觉判断不构成同方差、独立性或样本外泛化的统计检验。

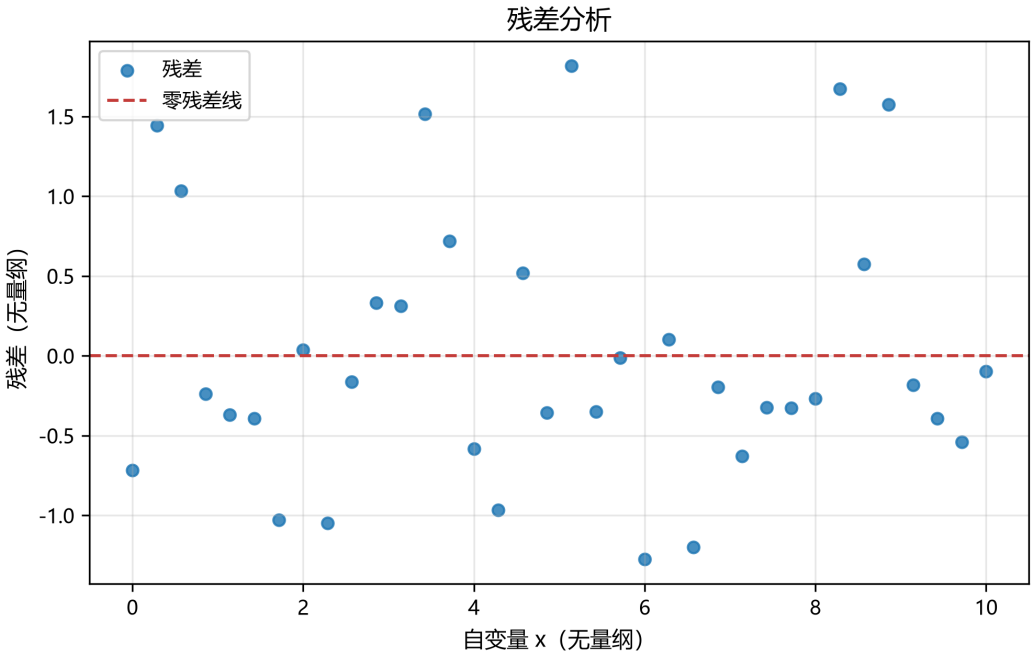



图 2: 残差分布

# 8 结论

在这组固定合成数据上，线性模型取得 RMSE=0.819939、MAE=0.647601、$R^2$=0.988464。这些数字来自 `metrics.json`，不是手工填入的独立结论。数据规模和生成机制限制了结论范围，因此结果只用于验证 MathModelAgent 的可执行闭环。

# 9 复现说明

复现运行保留固定输入、正式源码、配置和随机种子，并在隔离目录中重新执行各阶段。复现报告按浮点容差比较参数、指标、预测值和图表源数据，同时单独记录可能由元数据造成的 PNG、SVG 或 PDF 二进制差异。