带噪二维数据的线性拟合与可复现性验证

匿名

摘要

本文针对一组固定保存的带噪二维合成数据，建立带截距的一元线性最小二乘模型，通过独立子进程执行求解代码，并以结构化结果驱动图、表与本文生成。样本数为 36，拟合得到斜率 2.557205、截距 3.133504，均方根误差为 0.819939，决定系数为 0.988464。该示例只验证工程闭环，不代表真实竞赛数据或现实规律。

1 问题说明

给定文件 `data.csv` 中的观测对 (x_i, y_i)，要求估计线性关系，计算误差指标，分析残差，并生成可追溯的中文报告。输入是固定保存并进行哈希跟踪的 synthetic fixture；正式运行只读取该文件，不依赖重新生成观测。

2 模型假设

1. 在给定区间内，响应变量的条件均值可由线性函数近似；
2. 观测误差均值为零，且本示例不据此主张样本外泛化；
3. 所有观测在拟合中权重相同，输入文件无缺失值。

3 符号说明

符号	含义
x_i	第 i 个自变量观测
y_i	第 i 个响应变量观测
$\hat{y}_i$	模型预测值
$e_i = y_i - \hat{y}_i$	残差
a, b	斜率和截距

4 模型建立

采用模型

$$\hat{y}_i = a x_i + b, \tag{1}$$

并最小化残差平方和 $\sum_i (y_i - a x_i - b)^2$。误差指标定义为

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_i e_i^2}, \qquad \mathrm{MAE} = \frac{1}{n}\sum_i |e_i|, \tag{2}$$

$$R^2 = 1 - \frac{\sum_i e_i^2}{\sum_i (y_i - \bar{y})^2}. \tag{3}$$

5 求解方法

求解程序使用 SciPy 的非线性最小二乘接口估计 a, b，但模型本身为线性函数。Python `random` 和 NumPy 随机种子均固定为 20260710；求解阶段不重新生成数据。实际源码、命令、输入哈希、环境摘要、stdout 与 stderr 均保存在当前 run 目录。

6 结果

参数估计见表 1，误差指标见表 2。

表 1: 线性模型参数估计

参数	符号	原始数值	展示数值
斜率	a	2.5572047133	2.557205
截距	b	3.1335039092	3.133504

表 2: 拟合误差指标

指标	原始数值	展示数值
RMSE	0.8199391781	0.819939
MAE	0.6476007559	0.647601
R^2	0.9884643818	0.988464
最大绝对误差	1.8165114730	1.816511

原始观测与拟合曲线见图 1。该图直接读取实际预测结果生成。

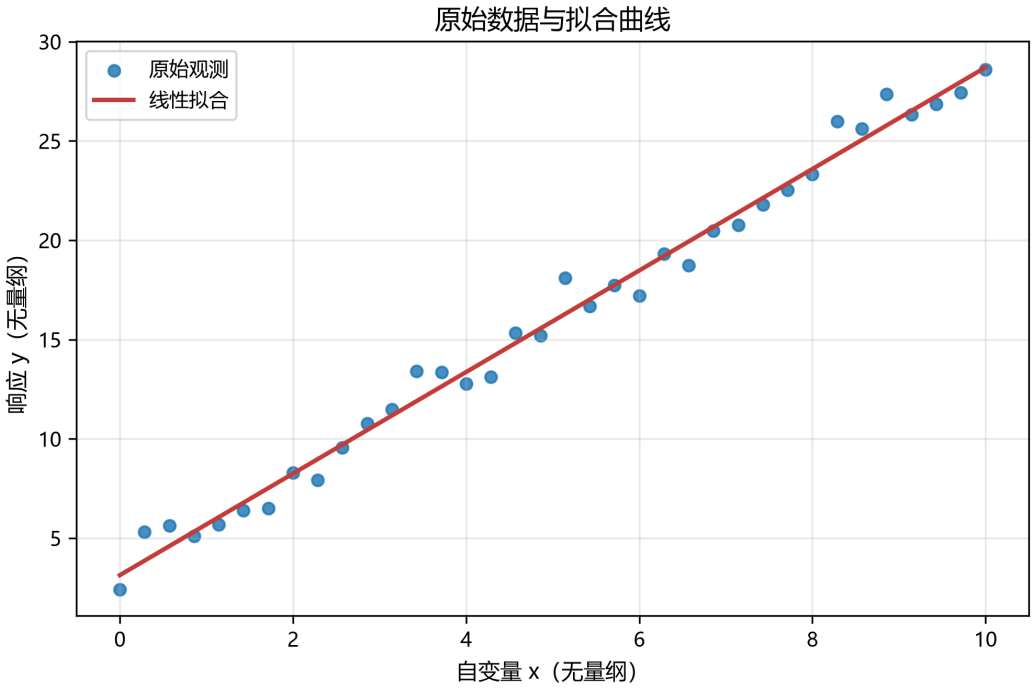


图 1: 原始数据与实际拟合曲线

7 误差分析

本次运行的 MAE 为 0.647601，最大绝对误差为 1.816511。独立验证器计算的残差均值为 -2.060e-15，在容差范围内接近零。图 2 给出残差随 x 的变化；图中未见需要在本工程 fixture 中进一步建模的明显单调趋势，但该视觉判断不构成同方差、独立性或样本外泛化的统计检验。

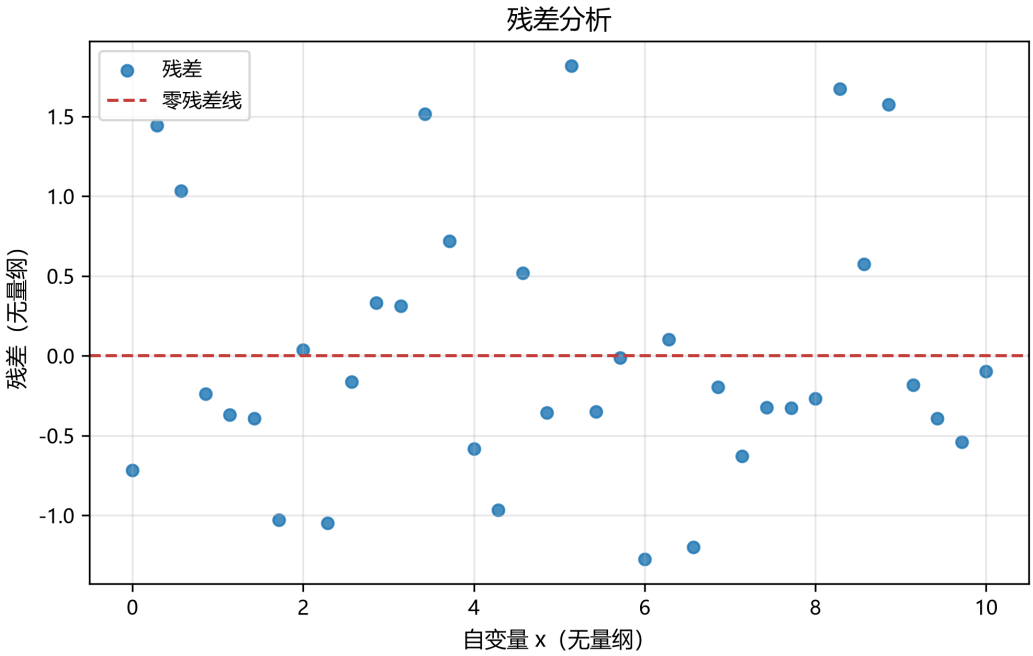


图 2: 残差分布

8 结论

在这组固定合成数据上，线性模型取得 RMSE=0.819939、MAE=0.647601、R^2=0.988464。这些数字来自 `metrics.json`，不是手工填入的独立结论。数据规模和生成机制限制了结论范围，因此结果只用于验证 MathModelAgent 的可执行闭环。

9 复现说明

复现运行保留固定输入、正式源码、配置和随机种子，并在隔离目录中重新执行各阶段。复现报告按浮点容差比较参数、指标、预测值和图表源数据，同时单独记录可能由元数据造成的 PNG、SVG 或 PDF 二进制差异。